

Assignment 10 of Machine Learning

111652001 Vincent Wu

1. Consider a forward SDE

$$dx_t = f(x_t, t) dt + g(x_t, t) dW_t,$$

show that the corresponding probability flow ODE is written as

$$dx_t = \left[f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x} g^2(x_t, t) - \frac{g^2(x_t, t)}{2} \frac{\partial}{\partial x} \log p(x_t, t) \right] dt.$$

We seek a deterministic Ordinary Differential Equation (ODE) of the form:

$$dx_t = \mathbf{u}(x_t, t) dt.$$

The probability density function $p(x, t)$ of the SDE satisfies the Fokker-Planck equation:

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}(fp) + \frac{1}{2} \frac{\partial^2}{\partial x^2}(g^2 p).$$

The probability density function $p(x, t)$ of the deterministic ODE $dx_t = \mathbf{u} dt$ satisfies the standard continuity equation:

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}(\mathbf{u}p).$$

For the ODE to have the same density evolution as the SDE, we equate the right-hand sides of the two evolution equations:

$$-\frac{\partial}{\partial x}(fp) + \frac{1}{2} \frac{\partial^2}{\partial x^2}(g^2 p) = -\frac{\partial}{\partial x}(\mathbf{u}p).$$

Integrating both sides of the equality with respect to x yields (assuming the constant of integration is zero):

$$fp - \frac{1}{2} \frac{\partial}{\partial x}(g^2 p) = \mathbf{u}p.$$

Hence, we solve for $\mathbf{u}$:

$$\begin{aligned} \mathbf{u} &= f - \frac{1}{2p} \frac{\partial}{\partial x}(g^2 p) \\ &= f - \frac{1}{2p} \left(p \frac{\partial g^2}{\partial x} + g^2 \frac{\partial p}{\partial x} \right) \\ &= f - \frac{1}{2} \frac{\partial g^2}{\partial x} - \frac{g^2}{2} \left(\frac{1}{p} \frac{\partial p}{\partial x} \right) \\ &= f - \frac{1}{2} \frac{\partial g^2}{\partial x} - \frac{g^2}{2} \frac{\partial}{\partial x} \ln p. \end{aligned}$$

Therefore, the corresponding probability flow ODE is written as

$$dx_t = \left(f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x} g^2(x_t, t) - \frac{g^2(x_t, t)}{2} \frac{\partial}{\partial x} \ln p(x_t, t) \right) dt.$$

□

2. AI 的未來與機器學習的基石

(a) AI 的未來能力

請具體描述一件你認為目前 AI 無法做到，但 20 年後有可能做到的重要事情。

(b) 涉及的機器學習類型

根據你對問題一的構想，判斷該能力的實現主要涉及哪一類機器學習方法。

(c) 第一步的「模型化」


假設要讓 AI 在 20 年後達到問題一的能力，請思考並設計出能夠作為第一個研究步驟的「簡化模型問題 (model problem)」。

(a) 我認為 AI 有可能在 20 年後實現《名偵探柯南：黑鐵的魚影》中的「全年齡認證」(All-Age Recognition) 系統，它被安裝在位於太平洋上、用以連接全球各地警備監控數據的「太平洋浮標」(Pacific Buoy) 設施內。一般的臉部辨識系統，就像你在手機上解鎖一樣，只能認出你「現在」的樣子，但這個「全年齡認證」系統厲害的地方在於：

1. 它看過全世界所有人的照片：它連接了全球各地的監視器和身份資料，等於它手上有全世界幾十億人的「從小到大」的各種照片。
2. 它會「猜」你長大或縮小的樣子：無論是一個人從小孩長大變老，或者像柯南、小哀一樣，吃了藥身體縮小，臉變回小孩子的樣子，這個系統都能靠著那些大量的照片，準確地比對出來，它能從一個小孩子的臉，推測他成年時的樣子；也能從一個人成年的樣子，倒推回他幼年時期的外貌。

在電影中，苦艾酒透過偽裝成相同面孔的人，便可讓系統判斷為是同一人。但走路姿勢也是識別一個人的一種方式，就算苦艾酒偽裝技術再厲害，我想也無法完美複製另一人的走路姿勢，因此我認為在 20 年後的「全年齡認證除了能從影像中識別、預測人臉，甚至具備處理動態影片的功能。


透過「全年齡認證」，警方在追蹤可疑人士或失蹤兒童時，可以輸入一張舊照片，讓系統分析或預測目標人物經過指定時間後的可能樣貌，這在找尋失蹤多年的人口時有很大幫助。但現實生活中，若政府或大型機構部署類似的「全年齡認證」系統，它可以將任何時期的影像都歸檔到你的個人檔案下，形同無處不在、跨越時間的監控，這會嚴重侵害個人的隱私權和自由。



(b) 要實現「全年齡認證」系統，我主要會利用監督式學習 (Supervised Learning) 與非監督式學習 (Unsupervised Learning)。

1. 監督式學習 (Supervised Learning)：主要負責最終的識別與預測功能，系統需要大量的「標籤化數據」，即同一個人的多張不同年齡、不同外貌狀態（輸入）與其唯一的身份 ID（目標訊號）進行配對訓練。
2. 非監督式學習 (Unsupervised Learning)：主要負責特徵提取與表徵學習，人臉和動態步態 (Gait) 影像數據維度高且複雜，年齡變化是一個巨大的干擾因素，非監督式方法，如自編碼器 (Autoencoders)，能從大量未標記的影像中學習並提取出穩定的潛在表徵 (Latent Representation)，例如步頻、步長比例、關節轉動的角度、雙腳著地時的身體晃動幅度，這些潛在表徵可以做為跨年齡識別的基礎。

系統的資料來源是來自全球各地的影像序列，包括靜態照片和動態步態影片，目標訊號除了個體的唯一身份 ID 外，還包括特定年齡的真實樣貌影像（用於訓練預測生成模型）。由於此系統較不需要與物理環境進行即時互動，因此其學習回饋主要透過損失函數 (Loss Function) 實現，例如將識別結果與真實標籤進行比對的分類損失，或將預測影像與真實影像進行比對的生成損失。



(c) 如果要在二十年後實現此系統，我想第一步是處理如何從有限的數據中學習到穩定的潛在表徵，因此，我們設計的簡化模型是透過「跨年齡小樣本身份識別」，來邁向最終的大規模、跨時間的識別 ($\text{Image}(t) \rightarrow \text{Identity ID}$)。

而簡化問題則將其縮減為一個二元分類問題：判斷兩張不同年齡的影像 $\text{Image}(t_1)$ 和 $\text{Image}(t_2)$ 是否為同一個人 ($\rightarrow \text{Yes/No}$)，這個簡化問題的意義在於它直接測試了模型能否成功地提取出「穩定的潛在表徵」，在面對年齡帶來的巨大外貌變化時，特徵仍能保持一致性。「小樣本」，是為了讓模型具備在僅看過極少數範例後，就能進行高泛化能力的識別。透過建立包含「同一人不同年齡」和「不同人」影像對的配對數據集，我們可以採用等錯誤率 (Equal Error Rate, EER)、準確率 (Accuracy) 和 AUC 作為評估指標。

為了判斷兩張跨年齡照片是否為同一人，我們必須將影像轉換為一串「身份特徵碼」，也就是將高維度的像素數據轉化為低維、具有意義的特徵向量，我們主要是採用卷積神經網絡 (CNN) 作為基礎，將輸入影像 I 映射到一個 D 維特徵向量 $f(I) \in \mathbb{R}^D$ ，這個向量 $f(I)$ 包含了影像中所有與身份相關的資訊。

為了確保不同影像的特徵提取方式一致，我們使用 Triplet Network，它內含三個共享同一套權重的 CNN 模塊，這保證了無論是輸入童年、成年還是老年的影像，它們都會以一致的方式被編碼。

在 Loss function 上，我們採用三元組損失 (Triplet Loss)，樣本是三個一組的 $\mathcal{T} = (A, P, N)$ ：

- A (Anchor)：基準樣本
- P (Positive)：與 A 同一身份的正樣本（跨年齡）
- N (Negative)：與 A 不同身份的負樣本

三元組損失要求 A 與 P 之間的距離 $d(A, P)$ 必須比 A 與 N 之間的距離 $d(A, N)$ 至少小於一個預先設定的邊界 M (Margin)。這個 M 用於確保同類特徵之間有足夠清晰的隔離，即：

$$L = \max(0, d(A, P) - d(A, N) + M)$$

當不等式 $d(A, P) + M < d(A, N)$ 不成立時，損失 L 會產生正值，這會迫使網絡學習：縮短 A 和 P 的距離，拉大 A 和 N 的距離。一旦模型在未見過的測試集上達成足夠低的等錯誤率 (EER)，則更有機會達成「全年齡認證」系統。



3. Unanswered Questions

Can higher-order or adaptive step-size numerical integrators significantly reduce the number of steps for PF-ODE/reverse SDE sampling while maintaining sample quality?