

Assignment 11 of Machine Learning

111652001 Vincent Wu

1. 在目前已有的作業 (Week_1~10) 中你已經累積了許多未回答的問題。請整理並列出所有這些問題，並向 AI 詢問每一個問題是否有相對應的研究。

- 若有，請列出參考文獻 (reference)。請務必查證參考文獻的真實性，並附上有效的網址連結。
- 若無，表示這是個 open problem，目前尚無人知道解法。請嘗試將問題用更口語化的方式重新描述，使其更容易理解。

1. 在做 gradient descent 時，不同的初始參數 θ^0 的選擇是否都會收斂？都會收斂到相同的 $\tilde{\theta}$ ？learning rate α 該如何挑選？

- Wegstein, J. H. (1958). Accelerating convergence of iterative processes. Communications of the ACM, 1(6), 9-13.
- Glorot, X., & Bengio, Y. (2010, March). Understanding the difficulty of training deep feedforward neural networks. In Proceedings of the thirteenth international conference on artificial intelligence and statistics (pp. 249-256). JMLR Workshop and Conference Proceedings.
- Adam, K. D. B. J. (2014). A method for stochastic optimization. arXiv preprint arXiv:1412.6980, 1412(6).

2. In the locally weighted linear regression (LWLR), how to choose the parameter τ ?

- Loader, C. (2006). Local regression and likelihood. Springer Science & Business Media.

3. I have heard some introductions about autoencoders, but I don't understand them very well, and I want to know some practical applications of them.

- Hinton, G. E., & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. science, 313(5786), 504-507.

4. I have heard some introductions about Convolution Neural Network, but I don't understand them very well, and I want to know some practical applications of them.
 - Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems*, 25.
5. LDA assumes that each class follows a Gaussian distribution and shares the same covariance matrix. In real-world datasets, these assumptions are often violated. How might this affect the performance and reliability of LDA?
 - Hastie, T. (2009). *The elements of statistical learning: data mining, inference, and prediction*.
6. Is it possible to construct a generative model that interpolates between LDA and QDA by partially sharing covariance structure among classes? What would be the implications for bias-variance tradeoff and model interpretability?
 - Friedman, J. H. (1989). Regularized discriminant analysis. *Journal of the American statistical association*, 84(405), 165-175.
7. DSM is highly dependent on the noise being Gaussian and isotropic ($\mathcal{N}(0, \sigma^2 I)$) for the conditional score $\nabla_x \log p(x|x_0)$ to have a simple closed form. If non-Gaussian noise (like Laplacian or Uniform noise) were used, would DSM remain equivalent? If not, what new, computable loss function would be necessary to effectively train the score network?
 - Nachmani, E., Roman, R. S., & Wolf, L. (2021). Non gaussian denoising diffusion models. *arXiv preprint arXiv:2106.07582*.
8. In practical training, we typically use batch processing. When simultaneously sampling multiple x samples and multiple v projection vectors, what is the optimal sampling strategy? For example, for a batch of size B , is it better to sample a unique v_i for each x_i sample, or to share the same v vector across the entire batch? Which strategy provides a better trade-off between computational efficiency and gradient accuracy?
 - Song, Y., & Ermon, S. (2019). Generative modeling by estimating gradients of the data distribution. *Advances in neural information processing systems*, 32.

9. Can higher-order or adaptive step-size numerical integrators significantly reduce the number of steps for PF-ODE/reverse SDE sampling while maintaining sample quality?

- Lu, C., Zhou, Y., Bao, F., Chen, J., Li, C., & Zhu, J. (2022). Dpm-solver: A fast ode solver for diffusion probabilistic model sampling in around 10 steps. *Advances in neural information processing systems*, 35, 5775-5787.

2. Toy model/Solvable Model Problem in your final project.

假設要讓 AI 在 20 年後達到你 final project 中所描述的能力，請設計並實際解出一個目前可行的「簡化模型問題」，作為邁向該能力的第一步。

如果要在二十年後實現此系統，我想第一步是處理如何從有限的數據中學習到穩定的潛在表徵，因此，我們設計的簡化模型是透過「跨年齡小樣本身份識別」，來邁向最終的大規模、跨時間的識別 ($\text{Image}(t) \rightarrow \text{Identity ID}$)。

而簡化問題則將其縮減為一個二元分類問題：判斷兩張不同年齡的影像 $\text{Image}(t_1)$ 和 $\text{Image}(t_2)$ 是否為同一個人 ($\rightarrow \text{Yes/No}$)，這個簡化模型的核心任務不僅僅是輸出 Yes/No，而是要構建一個與年齡無關的特徵空間。

令 $\mathcal{X} \subset \mathbb{R}^n$ 為輸入影像空間，我們的目標是學習一個參數化的非線性函數 $f_\theta: \mathcal{X} \rightarrow \mathbb{R}^D$ ，其中 θ 為神經網絡參數， D 為特徵向量的維度，對於任意兩張影像 x_i, x_j ，若它們屬於同一身份（無論年齡差距多大），則其歐氏距離 $d(f_\theta(x_i), f_\theta(x_j))$ 應小於閾值 τ ；若屬於不同身份，則距離應大於 τ 。

如果 f_θ 能成功訓練，則向量 $v = f_\theta(x)$ 即為「身份特徵碼」。在未來的「全年齡認證」中，當警方輸入一張舊照片 x_{old} ，系統只需計算 $v_{old} = f_\theta(x_{old})$ ，然後在數據庫中尋找最近鄰 v_{target} ，即可鎖定目標。

在模型與方法上，我們採用 Siamese/Triplet 架構，使用 ResNet-50 作為基礎，Residual Connections 能學習到更細微的臉部骨骼與五官幾何特徵，這些特徵比皮膚紋理更抗老化。在 Triplet Network 中，處理 Anchor, Positive, Negative 的三個 CNN 完全共享同一組參數 θ ，這保證了特徵空間的唯一性。我們還需要將其結果轉化為一個精簡的「身份特徵碼」（特徵向量），也就是將特徵圖壓縮成 D 維向量，去除多餘資訊，只保留最關鍵的身份特徵。另外，我們將輸出向量縮放為單位長度，這使得所有特徵向量都分佈在一個 D 維的超球面上，防止影像亮度或對比度影響距離計算，並使 Triplet Loss 的收斂更穩定。

在 Loss function 上，我們採用 Triplet Loss，樣本是三個一組的 $\mathcal{T} = (A, P, N)$ ：

- A (Anchor)：基準樣本
- P (Positive)：與 A 同一身份的正樣本（跨年齡）
- N (Negative)：與 A 不同身份的負樣本

Triplet Loss 公式為：

$$\mathcal{L} = \sum_i \max(0, \|f(x_i^A) - f(x_i^P)\|_2^2 - \|f(x_i^A) - f(x_i^N)\|_2^2 + \tau)$$

其中 τ 是閾值。

隨著訓練進行，隨機選取的 Triplet 大部分會很容易滿足條件（即 $d(A, P) + \tau < d(A, N)$ ），導致 Loss 為 0，模型停止學習。為了讓模型具備「小樣本」泛化能力，我們採用 Hard Negative Mining 策略：在每一個訓練 Batch 中，針對每一個 Anchor A ，我們不隨機選 N ，而是刻意挑選那些「長得最像 A 的不同人」（Hard Negative），強迫模型去區分那些細微的差異（例如區分兩個長得很像的老人）。

在數據的輸入上，我們隨機選取 P 個不同的身份 (Identity)，每個身份隨機選取 K 張不同年齡的照片，即 $\text{Batch Size} = P \times K$ 。假設 $P = 8, K = 4$ ：這個 Batch 裡會有 8 個人，每人有 4 張不同年齡的照片。

- 對於 Anchor (A)：模型可以在這 4 張照片中，任選一張當基準。
- 對於 Positive (P)：模型可以在該人剩下的 3 張照片中，選一張當正樣本（例如 A 是 5 歲， P 是 40 歲）。
- 對於 Negative (N)：模型可以從 Batch 裡剩下的其他 7 個人（28 張照片）中，挑選一張當負樣本。
- Hard Negative Mining：系統在這 28 張負樣本中，找出「長得最像 A 的那個人」來計算 Loss，強迫模型學得更精準。

模型訓練完成後，我們透過以下步驟評估其在「未見過的測試集」上的效能：

1. 距離矩陣計算：計算測試集中所有影像兩兩之間的歐氏距離。
2. ROC 曲線繪製：
 - 設定一系列變動的距離閾值 τ 。

- 真陽性率 (TAR, True Accept Rate): 同一人被正確判定為同一人的比例。
 - 假陽性率 (FAR, False Accept Rate): 不同人被錯誤判定為同一人的比例。
3. 等錯誤率 (EER): 找到一個閾值 τ ，使得 $FAR(\tau) = 1 - TAR(\tau)$ (即錯誤接受率等於錯誤拒絕率)，EER 越低，代表系統在嚴格的安全性和便利性之間取得了更好的平衡。